

FINAL PROJECT DATA SCIENCE

IDX Partners

BY. VENANSIA JULIAMA LAOLI



Problem Research


- Perusahaan fintech menghadapi risiko gagal bayar karena tidak semua nasabah mampu melunasi pinjaman. Terdapat dua risiko utama dalam proses kredit, yaitu menyetujui nasabah yang berpotensi gagal bayar dan menolak nasabah yang sebenarnya layak kredit. Kedua kondisi tersebut dapat menyebabkan kerugian finansial maupun hilangnya potensi pendapatan. Oleh karena itu, diperlukan model Machine Learning untuk memprediksi probabilitas gagal bayar agar keputusan pemberian kredit menjadi lebih akurat..
- Project ini bertujuan membangun model prediksi *loan default* serta mengidentifikasi fitur-fitur yang paling berpengaruh untuk mendukung interpretasi bisnis. Target variabel yang digunakan adalah *Loan Status* dengan label 0 (*Good*) dan 1 (*Bad*). Evaluasi model difokuskan pada metrik Recall sebagai prioritas utama, serta didukung oleh ROC-AUC, F1-Score, dan Precision.

Data Preperation Pipeline

1. Cleaning: Target mapping & remove leakage
2. Transformation: Type conversion & handling nulls
3. Enineering: Ratio features & encoding
4. Balancing: Scaling & SMOTE


Data Visualization and Business Insight

Distribusi Loan Status (Good vs Bad Loan)




Mayoritas pinjaman termasuk kategori Good Loan. Dataset menunjukkan class imbalance antara Good Loan dan Bad Loan. Penanganan imbalance penting agar model mampu mendeteksi risiko kredit secara efektif. Fokus bisnis utama adalah meminimalkan kesalahan prediksi pada kategori Bad Loan.


Distribusi loan_amnt



Distribusi annual_inc




Distribusi dti



loan_amnt menunjukkan preferensi borrower pada nominal pinjaman tertentu. annual_inc memiliki distribusi sangat skewed dan mengandung outlier tinggi. dti relatif terdistribusi normal dan berpotensi menjadi indikator risiko kredit yang penting. Beberapa fitur memerlukan preprocessing seperti scaling dan handling outlier sebelum modeling.

Data Visualization and Business Insight



int_rate menjadi variabel paling berpengaruh terhadap loan_status. Tidak ada fitur tunggal dengan korelasi sangat kuat terhadap target. Terdapat multikolinearitas tinggi pada fitur revolving credit. Model prediksi kemungkinan membutuhkan kombinasi banyak fitur dan algoritma non-linear untuk performa optimal.




Machine Learning Implementation and Evaluation


Perbandingan Model:

	Model	Recall	Precision	F1-Score	ROC-AUC
0	XGBoost	0.6769	0.1829	0.2880	0.6866
1	LightGBM	0.6742	0.1831	0.2880	0.6867
2	Logistic Regression	0.6283	0.1830	0.2834	0.6748

ROC Curve - Perbandingan Model



Top 15 Best Feature: Recall Tinggi



Business Recommendation

- Model machine learning terbukti mampu membantu prediksi risiko kredit secara lebih efektif.
- XGBoost dan LightGBM menjadi model paling optimal untuk credit risk classification.
- Faktor kemampuan bayar borrower menjadi indikator utama risiko kredit.
- Implementasi model secara terintegrasi dapat membantu perusahaan:
 - menurunkan bad loan,
 - meningkatkan kualitas approval,
 - dan mengoptimalkan profitabilitas bisnis lending



TERIMAKASIH

Github: <https://github.com/Juliamma26/idx-partners-ds-project>

File ZIP: https://drive.google.com/file/d/1v02x7Vl6e-EjBd6aYS6AHFPc28T-0p_i/view?usp=sharing